

Redes neuronales Tarea

María Isabel Chuya-Nataly Quintanilla

Tarea REDES NEURONALES

1. Descripción de los mismos numérica y gráficamente
2. Entender las fortalezas y debilidades del ANN perceptrón
4. Saber qué son las funciones de activación
5. Realizar un modelo preliminar de una capa sobre la clasificación benigno o maligno
6. Mejorar el modelo
7. Comparación de resultados mediante una matriz de confusión

Fortalezas y debilidades del ANN perceptrón

Fortalezas:

1. Capacidad de aprendizaje no lineal: un perceptrón de ANN puede aprender y representar funciones no lineales, a diferencia de un perceptrón simple. Un perceptrón en un ANN puede capturar relaciones más complejas entre las características de entrada y las salidas deseadas al agregar capas ocultas con funciones de activación no lineales, como la función sigmoide o ReLU.
2. Mayor capacidad de representación: En comparación con un perceptrón simple, un perceptrón en un ANN tiene una mayor capacidad de representación debido a su estructura multicapa y las conexiones entre capas. Puede aprender las características abstractas y las representaciones jerárquicas de los datos, lo que lo hace adecuado para abordar problemas más complejos y tareas de aprendizaje más difíciles.
3. Aprendizaje con retroalimentación: la retropropagación del error, un algoritmo efectivo para ajustar los pesos y sesgos de la red neuronal, permite que los perceptrones de una red neuronal aprendan. La retroalimentación del error ayuda a la red a aprender de sus errores y mejorar su rendimiento con el tiempo.

Debilidades:

1. La complejidad computacional aumenta significativamente a medida que se agregan capas y conexiones en un ANN. Esto implica que, en comparación con un perceptrón simple, el entrenamiento y la predicción pueden requerir más tiempo y recursos computacionales.
2. Posibles sobreajustes: Cuando los ANN se entrenan con conjuntos de datos pequeños o ruidosos, es posible que se sobreajusten. En lugar de generalizar patrones más amplios, la red puede memorizar los datos de entrenamiento. Se necesitan métodos de regularización, como reducir la tasa de aprendizaje o incluir términos de regularización.
3. Dificultades de interpretación: La complejidad de ANN puede dificultar la comprensión del proceso de toma de decisiones de la red. La interpretación de los resultados de un ANN puede ser más difícil en comparación con modelos más simples y lineales debido a la naturaleza de la representación distribuida y las conexiones no lineales.
4. Mayor necesidad de datos de entrenamiento: Para que las ANNs funcionen correctamente, especialmente las con múltiples capas, pueden requerir una cantidad significativa de datos de entrenamiento. El ANN puede no poder comprender adecuadamente la complejidad del problema y sufrir de baja generalización si tiene pocos datos de entrenamiento.

Funciones de Activación

Las funciones de activación de las redes neuronales se aplican a la salida de una neurona o unidad de procesamiento de una red neuronal. Estas características permiten que las redes neuronales capturen patrones y relaciones más complejos en los datos y introducen la no linealidad en la red.

Las funciones de activación se aplican a todas las entradas de una neurona, incluido el sesgo, y producen una salida que se transmite a las neuronas de la siguiente capa. Dado que permiten que la salida de una neurona no sea simplemente una combinación lineal de entradas, estas funciones introducen no linealidad en la red.

Cargar Librerías

Se cargan las librerías al inicio, puesto que ayuda a que todo el código se desarrolle de manera continua.

```
library(ggplot2)
library(e1071)
library(dplyr)
```

Attaching package: 'dplyr'

The following objects are masked from 'package:stats':

filter, lag

The following objects are masked from 'package:base':

intersect, setdiff, setequal, union

```
library(reshape2)
library(corrplot)
```

corrplot 0.92 loaded

```
library(caret)
```

Loading required package: lattice

```
library(kernlab)
```

Attaching package: 'kernlab'

The following object is masked from 'package:ggplot2':

alpha

```
library(pROC)
```

Type 'citation("pROC")' for a citation.

Attaching package: 'pROC'

The following objects are masked from 'package:stats':

cov, smooth, var

```
library(gridExtra)
```

Attaching package: 'gridExtra'

The following object is masked from 'package:dplyr':

combine

```
library(grid)
library(ggfortify)
library(purrr)
```

Attaching package: 'purrr'

The following object is masked from 'package:kernlab':

cross

The following object is masked from 'package:caret':

lift

```
library(nnet)
library(ggstatsplot)
```

You can cite this package as:

Patil, I. (2021). Visualizations with statistical details: The 'ggstatsplot' approach. Journal of Open Source Software, 6(61), 3167, doi:10.21105/joss.03167

```
library(knitr)
library(lavaan)
```

This is lavaan 0.6-15

lavaan is FREE software! Please report any bugs.

```
library(doParallel) # parallel processing
```

Loading required package: foreach

Attaching package: 'foreach'

The following objects are masked from 'package:purrr':

accumulate, when

Loading required package: iterators

Loading required package: parallel

```
registerDoParallel()
require(foreach)
require(iterators)
require(parallel)
library(tidymodels)
```

Registered S3 method overwritten by 'parsnip':

method from
autoplot.glmnet ggfortify

-- Attaching packages ----- tidymodels 1.1.0 --

v broom	1.0.4	v tibble	3.2.1
v dials	1.2.0	v tidyr	1.3.0
v infer	1.0.4	v tune	1.1.1
v modeldata	1.1.0	v workflows	1.1.3
v parsnip	1.1.0	v workflowsets	1.0.1
v recipes	1.0.6	v yardstick	1.2.0
v rsample	1.1.1		

```
-- Conflicts ----- tidymodels_conflicts() --
x foreach::accumulate() masks purrr::accumulate()
x scales::alpha() masks kernlab::alpha(), ggplot2::alpha()
x gridExtra::combine() masks dplyr::combine()
x purrr::cross() masks kernlab::cross()
x scales::discard() masks purrr::discard()
x dplyr::filter() masks stats::filter()
x dplyr::lag() masks stats::lag()
x purrr::lift() masks caret::lift()
x rsample::permutations() masks e1071::permutations()
x yardstick::precision() masks caret::precision()
x yardstick::recall() masks caret::recall()
x yardstick::sensitivity() masks caret::sensitivity()
x yardstick::specificity() masks caret::specificity()
x recipes::step() masks stats::step()
x tune::tune() masks parsnip::tune(), e1071::tune()
x recipes::update() masks lavaan::update(), stats::update()
x foreach::when() masks purrr::when()
* Learn how to get started at https://www.tidymodels.org/start/
```

```
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v forcats 1.0.0 v readr 2.1.4
v lubridate 1.9.2 v stringr 1.5.0
```

```
-- Conflicts ----- tidyverse_conflicts() --
x foreach::accumulate() masks purrr::accumulate()
x scales::alpha() masks kernlab::alpha(), ggplot2::alpha()
x readr::col_factor() masks scales::col_factor()
x gridExtra::combine() masks dplyr::combine()
x purrr::cross() masks kernlab::cross()
x scales::discard() masks purrr::discard()
x dplyr::filter() masks stats::filter()
x stringr::fixed() masks recipes::fixed()
x dplyr::lag() masks stats::lag()
x purrr::lift() masks caret::lift()
x readr::spec() masks yardstick::spec()
x foreach::when() masks purrr::when()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
library(ggthemes)
library(skimr)
library(DataExplorer)
library(ggpubr)
library(mosaicData)
library(h2o)
```

Your next step is to start H2O:

```
> h2o.init()
```

For H2O package documentation, ask for help:

```
> ??h2o
```

After starting H2O, you can use the Web UI at <http://localhost:54321>

For more information visit <https://docs.h2o.ai>

Attaching package: 'h2o'

The following objects are masked from 'package:lubridate':

```
day, hour, month, week, year
```

The following object is masked from 'package:PROC':

```
var
```

The following objects are masked from 'package:stats':

```
cor, sd, var
```

The following objects are masked from 'package:base':

```
&&, %*%, %in%, ||, apply, as.factor, as.numeric, colnames,
colnames<-, ifelse, is.character, is.factor, is.numeric, log,
log10, log1p, log2, round, signif, trunc
```

```
library(neuralnet)
```

Attaching package: 'neuralnet'

The following object is masked from 'package:dplyr':

compute

```
library(NeuralNetTools)
```

Cargar Datos

- Para cargar los datos se establece una variable y se lee los datos cargados en la misma carpeta “read.csv(“./wdbc.data”), header=T)”
- Se usa el comando “head()” para visualizar las primeras filas de un conjunto de datos o un objeto en forma de tabla.
- Se usa el comando “summary(datos)” para obtener las estadísticas descriptivas de las variables
- Se usa el comando “str(datos)” para realizar el análisis estadístico de los datos

```
# Cargar los datos
datos <- read.csv("./wdbc.data", header = T)
datos.numericos <- datos[, which(unlist(lapply(datos, is.numeric)))]
colnames(datos.numericos) <- paste0("Var", rep(1:10))
datos <- datos[, 1:10]
colnames(datos) <- c("ID_number", "Diagnosis", "radius1", "texture1",
                    "perimeter1", "area1", "smoothness1", "compactness1",
                    "concavity1", "concave_points1")

# Explorar los datos
head(datos) # Ver las primeras filas del conjunto de datos
```

	ID_number	Diagnosis	radius1	texture1	perimeter1	area1	smoothness1
1	842517	M	20.57	17.77	132.90	1326.0	0.08474
2	84300903	M	19.69	21.25	130.00	1203.0	0.10960
3	84348301	M	11.42	20.38	77.58	386.1	0.14250

4	84358402	M	20.29	14.34	135.10	1297.0	0.10030
5	843786	M	12.45	15.70	82.57	477.1	0.12780
6	844359	M	18.25	19.98	119.60	1040.0	0.09463

	compactness1	concavity1	concave_points1
1	0.07864	0.0869	0.07017
2	0.15990	0.1974	0.12790
3	0.28390	0.2414	0.10520
4	0.13280	0.1980	0.10430
5	0.17000	0.1578	0.08089
6	0.10900	0.1127	0.07400

```
summary(datos) # Obtener estadísticas descriptivas de las variables
```

ID_number	Diagnosis	radius1	texture1
Min. : 8670	Length:568	Min. : 6.981	Min. : 9.71
1st Qu.: 869222	Class :character	1st Qu.:11.697	1st Qu.:16.18
Median : 906157	Mode :character	Median :13.355	Median :18.86
Mean : 30423820		Mean :14.120	Mean :19.31
3rd Qu.: 8825022		3rd Qu.:15.780	3rd Qu.:21.80
Max. :911320502		Max. :28.110	Max. :39.28

perimeter1	area1	smoothness1	compactness1
Min. : 43.79	Min. : 143.5	Min. :0.05263	Min. :0.01938
1st Qu.: 75.14	1st Qu.: 420.2	1st Qu.:0.08629	1st Qu.:0.06481
Median : 86.21	Median : 548.8	Median :0.09587	Median :0.09252
Mean : 91.91	Mean : 654.3	Mean :0.09632	Mean :0.10404
3rd Qu.:103.88	3rd Qu.: 782.6	3rd Qu.:0.10530	3rd Qu.:0.13040
Max. :188.50	Max. :2501.0	Max. :0.16340	Max. :0.34540

concavity1	concave_points1
Min. :0.00000	Min. :0.00000
1st Qu.:0.02954	1st Qu.:0.02031
Median :0.06140	Median :0.03345
Mean :0.08843	Mean :0.04875
3rd Qu.:0.12965	3rd Qu.:0.07373
Max. :0.42680	Max. :0.20120

```
str(datos)
```

```
'data.frame': 568 obs. of 10 variables:
 $ ID_number      : int  842517 84300903 84348301 84358402 843786 844359 84458202 844981 845
 $ Diagnosis      : chr  "M" "M" "M" "M" ...
```

```

$ radius1      : num  20.6 19.7 11.4 20.3 12.4 ...
$ texture1     : num  17.8 21.2 20.4 14.3 15.7 ...
$ perimeter1   : num  132.9 130 77.6 135.1 82.6 ...
$ area1        : num  1326 1203 386 1297 477 ...
$ smoothness1  : num  0.0847 0.1096 0.1425 0.1003 0.1278 ...
$ compactness1 : num  0.0786 0.1599 0.2839 0.1328 0.17 ...
$ concavity1   : num  0.0869 0.1974 0.2414 0.198 0.1578 ...
$ concave_points1: num  0.0702 0.1279 0.1052 0.1043 0.0809 ...

```

Descripcion numérica y gráfica

```

#Tabla de resusmen de datos
skim(datos)

```

Table 1: Data summary

Name	datos
Number of rows	568
Number of columns	10
Column type frequency:	
character	1
numeric	9
Group variables	None

Variable type: character

skim_variable	n_missing	complete_rate	min	max	empty	n_unique	whitespace
Diagnosis	0	1	1	1	0	2	0

Variable type: numeric


skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100	hist
ID_number	0	1	30423820125	124628670.00	869222.500	6157.088	25022.251	1320502.00		
radius1	0	1	14.12	3.52	6.98	11.70	13.36	15.78	28.11	
texture1	0	1	19.31	4.29	9.71	16.18	18.86	21.80	39.28	
perimeter1	0	1	91.91	24.29	43.79	75.13	86.21	103.88	188.50	

skim_variable	n_missing	n_complete	mean	sd	p0	p25	p50	p75	p100	hist
area1	0	1	654.28	351.92	143.50	420.18	548.75	782.62	2501.00	
smoothness1	0	1	0.10	0.01	0.05	0.09	0.10	0.11	0.16	
compactness1	0	1	0.10	0.05	0.02	0.06	0.09	0.13	0.35	
concavity1	0	1	0.09	0.08	0.00	0.03	0.06	0.13	0.43	
concave_points1	0	1	0.05	0.04	0.00	0.02	0.03	0.07	0.20	

```
# Número de datos ausentes por variable
# =====
datos %>% map_dbl(.f = function(x){sum(is.na(x))})
```

ID_number	Diagnosis	radius1	texture1	perimeter1
0	0	0	0	0
area1	smoothness1	compactness1	concavity1	concave_points1
0	0	0	0	0


```
plot_missing(
  data = datos,
  title = "Porcentaje de valores ausentes",
  ggtheme = theme_bw(),
  theme_config = list(legend.position = "none")
)
```



```
#diagrama de cajas unido  
datos.melt<-reshape2::melt((datos))
```

Using Diagnosis as id variables


```
ggplot(datos.melt,aes(y=value,fill=variable))+geom_boxplot()
```



```
#grafica de densidad
datos.melt<-reshape2::melt((datos))
```

Using Diagnosis as id variables


```
ggplot(datos.melt,aes(x=value))+geom_density()
```




```
#csa<- as.data.frame(datos.test)
```

```
#PCA  
cancer.pca <- prcomp(datos.numericos[, 1:10], center=TRUE, scale=TRUE)  
plot(cancer.pca, type="l", main='')  
grid(nx = 10, ny = 14)  
title(main = "PCA", sub = NULL, xlab = "Components")  
box()
```


PCA



```
pca_df <- as.data.frame(cancer.pca$x)
ggplot(pca_df, aes(x=PC1, y=PC2, col=datos$Diagnosis)) + geom_point(alpha=0.5)
```



```
# Gráfico de distribución para cada variable numérica
# =====
datos1<- datos[,-2]
plot_density(
  data      = datos %>% select(-ID_number),
  ncol      = 3,
  title     = "Distribución variables continuas",
  ggtheme   = theme_bw(),
  theme_config = list(
    plot.title = element_text(size = 14, face = "bold"),
    strip.text = element_text(colour = "black", size = 12, face = 2)
  )
)
```



```
# Reparto de datos en train y test
# =====
n<-nrow(datos)
set.seed(123456)

datos$Diagnosis<-as.factor(datos$Diagnosis)
```



```

train <- sample(n,floor(n*0.7))
datos.train <- datos[train,]
datos.test  <- datos[-train,]

csa<- as.data.frame(datos.test)

# Se almacenan en un objeto `recipe` todos los pasos de preprocesado y, finalmente,
# se aplican a los datos.
transformer <- recipe(
  formula = ID_number ~ .,
  data = datos.train
) %>%
step_naomit(all_predictors()) %>%
step_nzv(all_predictors()) %>%
step_center(all_numeric(), -all_outcomes()) %>%
step_scale(all_numeric(), -all_outcomes()) %>%
step_dummy(all_nominal(), -all_outcomes())

transformer

```

-- Recipe -----

-- Inputs

Number of variables by role

```

outcome:  1
predictor: 9

```

-- Operations

* Removing rows with NA values in: all_predictors()

```

* Sparse, unbalanced variable filter on: all_predictors()

* Centering for: all_numeric(), -all_outcomes()

* Scaling for: all_numeric(), -all_outcomes()

* Dummy variables from: all_nominal(), -all_outcomes()

```

```

# Se entrena el objeto recipe
transformer_fit <- prep(transformer)

# Se aplican las transformaciones al conjunto de entrenamiento y de test
datos_train_prep <- bake(transformer_fit, new_data = datos.train)
datos_test_prep <- bake(transformer_fit, new_data = datos.test)

glimpse(datos_train_prep)

```

```

Rows: 397
Columns: 10
$ radius1      <dbl> -1.13514497, -1.30682691, 1.39880068, -0.15573227, 1.8~
$ texture1     <dbl> -1.03994386, -0.79907142, 1.28225362, 1.25419081, 0.49~
$ perimeter1   <dbl> -1.1390348, -1.3177976, 1.4868003, -0.1830249, 1.65979~
$ area1        <dbl> -0.9821227, -1.0741236, 1.2740359, -0.2395643, 1.84939~
$ smoothness1  <dbl> 1.176845256, -0.810772101, -0.384360449, -0.262034903,~
$ compactness1 <dbl> -0.453929138, -1.193750788, 2.122415050, -0.490976070,~
$ concavity1   <dbl> -0.97825620, -0.90683930, 1.53466306, -0.45004776, 0.0~
$ concave_points1 <dbl> -0.94276622, -0.84467861, 1.31324874, -0.47574432, 0.2~
$ ID_number     <int> 858970, 882488, 855625, 866083, 883263, 873701, 881472~
$ Diagnosis_M   <dbl> 0, 0, 1, 1, 1, 1, 0, 0, 1, 0, 0, 1, 1, 0, 0, 0, 1, 1, ~

```

```

# Inicialización del cluster
# =====
h2o.init(
  nthreads = -1,
  max_mem_size = "4g"
)

```

Connection successful!

R is connected to the H2O cluster:

```
H2O cluster uptime:      5 days 22 hours
H2O cluster timezone:    America/Guayaquil
H2O data parsing timezone: UTC
H2O cluster version:     3.40.0.4
H2O cluster version age:  2 months and 4 days
H2O cluster name:        H2O_started_from_R_isach_wfo456
H2O cluster total nodes: 1
H2O cluster total memory: 3.23 GB
H2O cluster total cores: 8
H2O cluster allowed cores: 8
H2O cluster healthy:     TRUE
H2O Connection ip:       localhost
H2O Connection port:     54321
H2O Connection proxy:    NA
H2O Internal Security:   FALSE
R Version:                R version 4.2.3 (2023-03-15)
```

```
# Se eliminan los datos del cluster por si ya había sido iniciado.
```

```
h2o.removeAll()
h2o.no_progress()
```

```
datos_train <- as.h2o(datos_train_prep, key = "datos.train")
```

```
datos_test  <- as.h2o(datos_test_prep, key = "datos.test")
```

```
# Espacio de búsqueda de cada hiperparámetro
```

```
# =====
hiperparametros <- list(
  epochs = c(50, 100, 500),
  hidden = list(5, 10, 25, 50, c(10, 10))
)
```

```
# Búsqueda por validación cruzada
```

```
# =====
```

```
variable_respuesta <- 'radius1'
```

```
predictores <- setdiff(colnames(datos_train), variable_respuesta)
```

```
grid <- h2o.grid(
  algorithm = "deeplearning",
```

```

        activation = "Rectifier",
        x          = predictores,
        y          = variable_respuesta,
        training_frame = datos_train,
        nfolds      = 3, #validacion cruzada
        standardize  = FALSE,
        hyper_params = hiperparametros,
        search_criteria = list(strategy = "Cartesian"),
        seed         = 123456,
        grid_id      = "grid"
    )

```

Warning in h2o.getGrid(grid_id = grid_id): Some models were not built due to a failure, for more details run `summary(grid_object, show_stack_traces = TRUE)`

```

# Resultados del grid
# =====
resultados_grid <- h2o.getGrid(
    sort_by = 'rmse',
    grid_id = "grid",
    decreasing = FALSE
)

```

Warning in h2o.getGrid(sort_by = "rmse", grid_id = "grid", decreasing = FALSE): Some models were not built due to a failure, for more details run `summary(grid_object, show_stack_traces = TRUE)`

```
data.frame(resultados_grid@summary_table)
```

	epochs	hidden	model_ids	rmse
1	104.30646	5	grid_model_2	2.122026e+00
2	503.77978	10	grid_model_6	6.237714e+03
3	503.77978	5	grid_model_3	1.155008e+04
4	104.30646	25	grid_model_8	1.926905e+04
5	51.05105	5	grid_model_1	2.694265e+04
6	104.30646	10	grid_model_5	3.780233e+04
7	104.30646	50	grid_model_11	3.878753e+04
8	51.05105	10	grid_model_4	6.031864e+04
9	51.05105	50	grid_model_10	6.441599e+04

```

10 503.77978      50 grid_model_12 8.638660e+04
11  51.05105      25 grid_model_7 2.813358e+05
12 503.77978      25 grid_model_9 3.734522e+05

```

```

# Mejor modelo encontrado
# =====
modelo_final <- h2o.getModel(resultados_grid@model_ids[[1]])

predicciones <- h2o.predict(
  object = modelo_final,
  newdata = datos_test
)

predicciones <- predicciones %>%
  as_tibble() %>%
  mutate(valor_real = as.vector(datos_test$Diagnosis))

predicciones %>% head(10)

```

```

# A tibble: 10 x 2
  predict valor_real
    <dbl>      <int>
1    788.         1
2 78889.         1
3 79012.         1
4    790.         1
5   7929.         0
6   7930.         1
7    792.         1
8    794.         1
9    793.         1
10 79554.         1

```

```

rmse(predicciones, truth = valor_real, estimate = predict, na_rm = TRUE)

```

```

# A tibble: 1 x 3
  .metric .estimator .estimate
  <chr>   <chr>       <dbl>
1 rmse   standard    144677.

```

Figura percepción ANN

```
modelLookup("nnet")
```

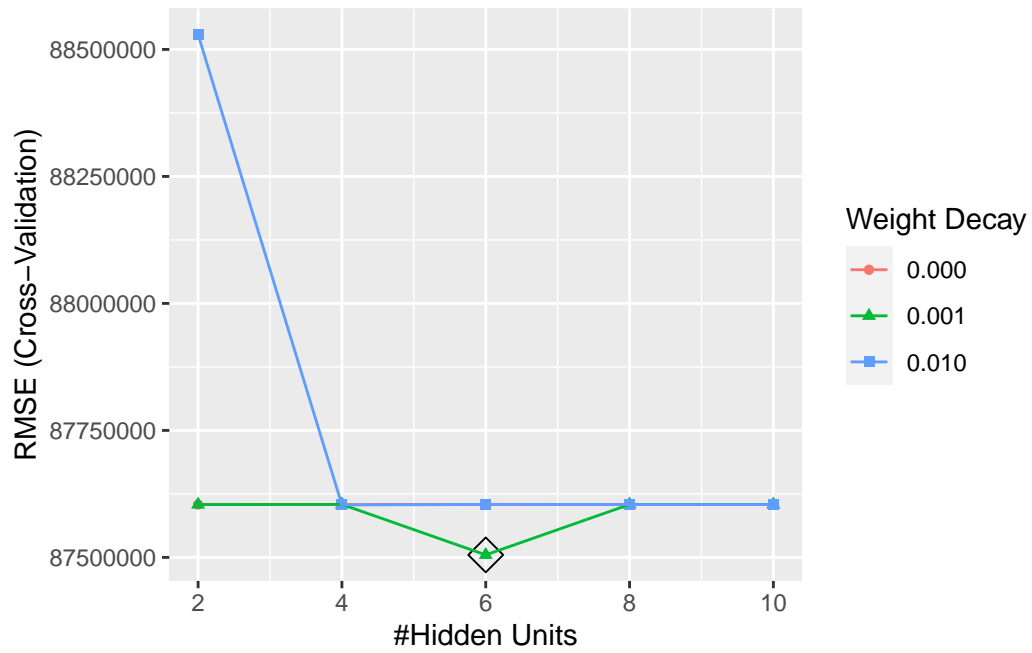
	model	parameter	label	forReg	forClass	probModel
1	nnet	size #Hidden Units		TRUE	TRUE	TRUE
2	nnet	decay Weight Decay		TRUE	TRUE	TRUE

```
tuneGrid <- expand.grid(size = 2*1:5, decay = c(0, 0.001, 0.01))
```


```
set.seed(123456)
caret.nnet <- train(ID_number ~ ., data = datos.train, method = "nnet",
  preProc = c("range"), # Reescalado en [0,1]
  tuneGrid = tuneGrid,
  trControl = trainControl(method = "cv", number = 10),
  linout = TRUE, maxit = 200, trace = FALSE)
```

Warning in nominalTrainWorkflow(x = x, y = y, wts = weights, info = trainInfo,
: There were missing values in resampled performance measures.

```
ggplot(caret.nnet, highlight = TRUE)
```



```
plotnet(caret.nnet$finalModel)
```



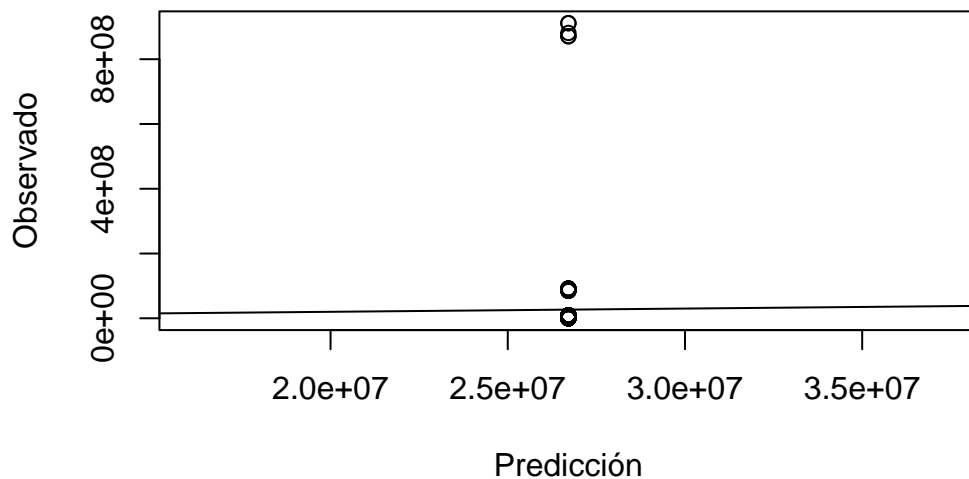
```

pred <- predict(caret.nnet, newdata = datos.test)
obs <- datos.test$ID_number

plot(pred, obs, main = "Observado frente a predicciones",
      xlab = "Predicción", ylab = "Observado")
abline(a = 0, b = 1)

```

Observado frente a predicciones



```

accuracy <- function(pred, obs, na.rm = FALSE,
                      tol = sqrt(.Machine$double.eps)) {
  err <- obs - pred      # Errores
  if(na.rm) {
    is.a <- !is.na(err)
    err <- err[is.a]
    obs <- obs[is.a]
  }
  perr <- 100*err/pmax(obs, tol) # Errores porcentuales
  return(c(
    me = mean(err),          # Error medio
    rmse = sqrt(mean(err^2)), # Raíz del error cuadrático medio
    mae = mean(abs(err)),    # Error absoluto medio
    mpe = mean(perr),        # Error porcentual medio
  ))
}

```



```

    mape = mean(abs(perr)), # Error porcentual absoluto medio
    r.squared = 1 - sum(err^2)/sum((obs - mean(obs))^2) # Pseudo R-cuadrado
  ))
}

accuracy(pred, obs)

```

	me	rmse	mae	mpe	mape
	1.233360e+07	1.507906e+08	5.335515e+07	-7.131313e+03	7.154155e+03
r.squared					
	-6.735132e-03				